

《相机标定学习手册》

该内容是公众号 计算机视觉life 旗下课程 《单目/鱼眼/双目/全景/阵列 相机标定：原理和实战》 的课件编纂成的课程手册。

说明：本文会随课程持续更新，由于笔者水平有限，编写过程难免存在错误或疏漏，读者如发现有错误，欢迎提出。

扫描一下，系统学习视觉/激光/多传感器融合SLAM、三维重建等精品课程：



扫描学习SLAM、三维重建

第四章 张正友标定法

1. 旋转矩阵
 - 1.1 欧拉角
 - 1.2 罗德里格斯旋转角
 - 1.3 旋转矩阵性质
2. 张正友标定法
 - 2.1 求解单应矩阵
 - 2.2 求解内参矩阵
 - 2.3 求解外参矩阵
 - 2.4 求解畸变系数
 - 2.5 最小二乘优化
3. 聊聊单应矩阵


第四章 张正友标定法

1. 旋转矩阵

一个坐标(系)在 3D 空间中的旋转表示有很多种，这里我们来看下欧拉角和罗德里格斯的表达形式

1.1 欧拉角

首先，我们先对二维的情况有个直观的了解



我们希望得到向量 $v(x, y)$ 绕原点旋转 θ 之后的位置 $v'(x', y')$, 这个从图中可以很直观的得到

$$\begin{aligned} x &= r \cos \phi \\ y &= r \sin \phi \\ x' &= r \cos (\theta + \phi) \\ y' &= r \sin (\theta + \phi) \end{aligned} \quad (1)$$

利用三角函数展开得到

$$\begin{aligned} x' &= r \cos \theta \cos \phi - r \sin \theta \sin \phi \\ y' &= r \sin \theta \cos \phi + r \cos \theta \sin \phi \end{aligned} \quad (2)$$


代入对应的 (x, y) 有

$$\begin{aligned} x' &= x \cos \theta - y \sin \theta \\ y' &= x \sin \theta + y \cos \theta \end{aligned} \quad (3)$$

矩阵形式表达为

$$\begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix} * \begin{bmatrix} x \\ y \end{bmatrix} \quad (4)$$

我们习惯性把逆时针作为角度的正方向。并且虽然上述示意图是锐角，但是其实对于任何角度都是适用的，有兴趣可以自行推导一下。



我们把上述情况推广到三维(使用右手坐标系)情况，上述旋转其实等价于绕 z 轴的旋转，并且明显，该旋转不会改变 z 的值，因此有

$$\begin{bmatrix} x' \\ y' \\ z' \end{bmatrix} = \begin{bmatrix} \cos \theta_z & -\sin \theta_z & 0 \\ \sin \theta_z & \cos \theta_z & 0 \\ 0 & 0 & 1 \end{bmatrix} * \begin{bmatrix} x \\ y \\ z \end{bmatrix} \quad (5)$$

类似的，我们把旋转扩展到绕 x 、 y 轴的旋转，有

- 绕 x 轴旋转

$$\begin{bmatrix} x' \\ y' \\ z' \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & \cos \theta_x & -\sin \theta_x \\ 0 & \sin \theta_x & \cos \theta_x \end{bmatrix} * \begin{bmatrix} x \\ y \\ z \end{bmatrix} \quad (6)$$


- 绕 y 轴旋转

$$\begin{bmatrix} x' \\ y' \\ z' \end{bmatrix} = \begin{bmatrix} \cos \theta_y & 0 & \sin \theta_y \\ 0 & 1 & 0 \\ -\sin \theta_y & 0 & \cos \theta_y \end{bmatrix} * \begin{bmatrix} x \\ y \\ z \end{bmatrix} \quad (7)$$

为什么这个式子和其他两个不同？

在一般的场景中，我们对绕着三个轴旋转的角度有另外的称呼，

- 绕 x 轴旋转的角度 θ_x ，也称为 roll，横滚角 γ
- 绕 y 轴旋转的角度 θ_y ，也称为 pitch，俯仰角 β
- 绕 z 轴旋转的角度 θ_z ，也称为 yaw，偏航角 α



对于三维空间中任何一个旋转矩阵，我们都可以使用前面三个矩阵来进行表示，如我们规定按照 $x - y - z$ 的方式进行旋转，则整体的旋转矩阵为

$$R = R_z(\alpha) R_y(\beta) R_x(\gamma) = \begin{bmatrix} \cos \alpha & -\sin \alpha & 0 \\ \sin \alpha & \cos \alpha & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \cos \beta & 0 & \sin \beta \\ 0 & 1 & 0 \\ -\sin \beta & 0 & \cos \beta \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & \cos \gamma & -\sin \gamma \\ 0 & \sin \gamma & \cos \gamma \end{bmatrix} \quad (8)$$

$$= \begin{bmatrix} \cos \alpha \cos \beta & \cos \alpha \sin \beta \sin \gamma - \sin \alpha \cos \gamma & \cos \alpha \sin \beta \cos \gamma + \sin \alpha \sin \gamma \\ \sin \alpha \cos \beta & \sin \alpha \sin \beta \sin \gamma + \cos \alpha \cos \gamma & \sin \alpha \sin \beta \cos \gamma - \cos \alpha \sin \gamma \\ -\sin \beta & \cos \beta \sin \gamma & \cos \beta \cos \gamma \end{bmatrix} \quad (9)$$


当然，如果使用 $y - z - x$ 或者诸如此类的旋转约定方式，得到旋转矩阵的表达式并不相同，这点大家需要注意，也可以自行推导。

尝试推导下不同旋转顺序下的旋转矩阵？

需要注意的是 **内旋(intrinsic rotation)/静态** 和 **外旋(extrinsic rotation)/动态**：内旋的每个旋转绕的是世界坐标系的轴，世界坐标系保持不变，外旋的每个旋转绕的是自身的坐标系的轴，每次轴是跟着一起旋转的，我们上述是采用外旋的方式来表达的。

万向锁：为一种使用动态欧拉角可能会存在的，丢失一个旋转分量的现象，我们使用一组图来说明：(图片来自<https://www.cnblogs.com/liuhuacai/p/12093770.html>)


1. 绕z轴旋转，得到新的坐标系，记为R。



上述过程中，绕 z 和 绕 x 轴其实都是同一个方向，因此说我们丢掉了旋转。

1.2 罗德里格斯旋转角

罗德里格斯形式的旋转矩阵使用一个单位旋转轴 k 和绕轴旋转的角度 θ （正方向右手定则）来描述



如上图，我们可以知道，向量 v 在 k 的作用下其实只旋转了垂直于旋转轴的分量，我们将 v 做分解，有

$$v = v_{\parallel} + v_{\perp} \quad (10)$$

其中平行分量使用投影和旋转轴表示为

$$v_{\parallel} = (v \cdot k)k \quad (11)$$

垂直分量表示为

$$v_{\perp} = v - v_{\parallel} = v - (v \cdot k)k = -k \times (k \times v) \quad (12)$$

平行于轴的分量在旋转时不会改变幅度和方向，

$$v_{\parallel \text{rot}} = v_{\parallel} \quad (13)$$

垂直于轴的分量只会改变方向，但不会改变大小

$$\begin{aligned} |v_{\perp \text{rot}}| &= |v_{\perp}| \\ v_{\perp} &= \cos \theta v_{\perp} + \sin \theta k \times v_{\perp} \end{aligned} \quad (14)$$

代入分解式

$$k \times v_{\perp} = k \times (v - v_{\parallel}) = k \times v - k \times v_{\parallel} = k \times v \quad (15)$$

因此上式可以修改为

$$v_{\perp} = \cos \theta v_{\perp} + \sin \theta k \times v \quad (16)$$

则

$$\mathbf{v}_{\text{rot}} = \mathbf{v}_{\parallel} + \cos(\theta) \mathbf{v}_{\perp} + \sin(\theta) \mathbf{k} \times \mathbf{v} \quad (17)$$

$$= \mathbf{v}_{\parallel} + \cos(\theta) (\mathbf{v} - \mathbf{v}_{\parallel}) + \sin(\theta) \mathbf{k} \times \mathbf{v} \quad (18)$$

$$= \cos(\theta) \mathbf{v} + (1 - \cos \theta) \mathbf{v}_{\parallel} + \sin(\theta) \mathbf{k} \times \mathbf{v} \quad (19)$$

$$= \cos(\theta) \mathbf{v} + (1 - \cos \theta) (\mathbf{k} \cdot \mathbf{v}) \mathbf{k} + \sin(\theta) \mathbf{k} \times \mathbf{v} \quad (20)$$

我们将叉乘部分按照矩阵分量形式表示出来

$$\begin{bmatrix} (\mathbf{k} \times \mathbf{v})_x \\ (\mathbf{k} \times \mathbf{v})_y \\ (\mathbf{k} \times \mathbf{v})_z \end{bmatrix} = \begin{bmatrix} k_y v_z - k_z v_y \\ k_z v_x - k_x v_z \\ k_x v_y - k_y v_x \end{bmatrix} = \begin{bmatrix} 0 & -k_z & k_y \\ k_z & 0 & -k_x \\ -k_y & k_x & 0 \end{bmatrix} \begin{bmatrix} v_x \\ v_y \\ v_z \end{bmatrix} \quad (21)$$

为了表达方便，我们定义一个叉乘矩阵 $\mathbf{K}$

$$\mathbf{K} = \begin{bmatrix} 0 & -k_z & k_y \\ k_z & 0 & -k_x \\ -k_y & k_x & 0 \end{bmatrix} \quad (22)$$

将叉乘简化为

$$\mathbf{K}\mathbf{v} = \mathbf{k} \times \mathbf{v} \quad (23)$$

由于 $\mathbf{k}$ 为单位向量，因此有单位 2-范数

$$\|\mathbf{K}\|_2 = 1 \quad (24)$$

我们回到之前的 $\mathbf{v}_{rot}$ 表达式上

$$\mathbf{v}_{rot} = \mathbf{v} \cos \theta + (\mathbf{k} \times \mathbf{v}) \sin \theta + \mathbf{k} (\mathbf{k} \cdot \mathbf{v}) (1 - \cos \theta) \quad (25)$$

$$= \mathbf{v} \cos \theta + (\mathbf{k} \times \mathbf{v}) \sin \theta + (\mathbf{v} - \mathbf{v}_\perp) (1 - \cos \theta) \quad (26)$$

$$= \mathbf{v} \cos \theta + (\mathbf{k} \times \mathbf{v}) \sin \theta + (\mathbf{v} + \mathbf{k} \times (\mathbf{k} \times \mathbf{v})) (1 - \cos \theta) \quad (27)$$

$$= \mathbf{v} \cos \theta + (\mathbf{k} \times \mathbf{v}) \sin \theta + (\mathbf{v} + \mathbf{K}(\mathbf{K}\mathbf{v})) (1 - \cos \theta) \quad (28)$$

$$= \mathbf{v} (\cos \theta + 1 - \cos \theta) + (\mathbf{k} \times \mathbf{v}) \sin \theta + \mathbf{K}(\mathbf{K}\mathbf{v}) (1 - \cos \theta) \quad (29)$$

这里我们就得到了

$$\mathbf{v}_{rot} = \mathbf{v} + (\sin \theta) \mathbf{K}\mathbf{v} + (1 - \cos \theta) \mathbf{K}^2 \mathbf{v}, \quad \|\mathbf{K}\|_2 = 1 \quad (30)$$

那么旋转矩阵就可以使用上式得到

$$\mathbf{R} = \mathbf{I} + \sin \theta \mathbf{K} + (1 - \cos \theta) \mathbf{K}^2 \quad (31)$$

展开之后有

$$\mathbf{R}(k, \theta) = \begin{bmatrix} \cos \theta + k_x^2 (1 - \cos \theta) & -\sin \theta k_z + (1 - \cos \theta) k_x k_y & \sin \theta k_y + (1 - \cos \theta) k_x k_z \\ \sin \theta k_z + (1 - \cos \theta) k_x k_y & \cos \theta + k_y^2 (1 - \cos \theta) & -\sin \theta k_x + (1 - \cos \theta) k_y k_z \\ -\sin \theta k_y + (1 - \cos \theta) k_x k_z & \sin \theta k_x + (1 - \cos \theta) k_y k_x & \cos \theta + k_z^2 (1 - \cos \theta) \end{bmatrix} \quad (32)$$

1.3 旋转矩阵性质

- 每一行每一列的模，都为1
- 任意两个列向量或者任意两个行向量都是正交的
- 正交矩阵的逆 (inverse) 等于正交矩阵的转置 (transpose)

2. 张正友标定法

我们来捋一下张正友标定法的流程

根据相机模型并暂时忽略畸变，有

$$s \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \mathbf{A} \begin{bmatrix} R & T \end{bmatrix} \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix} = \mathbf{A} \begin{bmatrix} r_1 & r_2 & r_3 & t \end{bmatrix} \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix} \quad (33)$$

其中

$$\mathbf{A} = \begin{bmatrix} \alpha & \gamma & u_0 \\ 0 & \beta & v_0 \\ - & - & - \end{bmatrix} \quad (34)$$

$$\begin{bmatrix} 0 & 0 & 1 \end{bmatrix}$$

2.1 求解单应矩阵

考虑到我们标定时使用的是平面标定板，我们将 XOY 平面设置为标定板平面上， z 轴垂直向外，这样对于检测的所有特征点都有

$$Z_W = 0 \quad (35)$$

代入上式，有

$$s \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \mathbf{A} [R \quad T] \begin{bmatrix} X_w \\ Y_w \\ 0 \\ 1 \end{bmatrix} = A [r_1 \quad r_2 \quad t] \begin{bmatrix} X_w \\ Y_w \\ 1 \end{bmatrix} \quad (36)$$

这里 r_i 代表旋转矩阵的第 i 个列向量。令 $\widetilde{M} = [X \quad Y \quad 1]$, $\widetilde{m} = [u \quad v \quad 1]$, 上式简写为

$$s\widetilde{m} = H\widetilde{M} \quad (37)$$

我们称 H 为单应矩阵，把矩阵展开，有

$$\begin{cases} su &= h_{11}X + h_{12}Y + h_{13} \\ sv &= h_{21}X + h_{22}Y + h_{23} \\ s &= h_{31}X + h_{32}Y + h_{33} \end{cases} \quad (38)$$

从而有

$$\begin{cases} uXh_{31} + uYh_{32} + h_{33}u &= h_{11}X + h_{12}Y + h_{13} \\ vXh_{31} + vYh_{32} + h_{33}v &= h_{21}X + h_{22}Y + h_{23} \end{cases} \quad (39)$$

可以看到，如果对两个式子都除以 h_{33} ，并不会对整体的形式产生影响，因此，我们一般令 $h_{33} = 1$ 。

也就是说，对于单应矩阵，其自由度并不是 9，而是 8

定义

$$h' = [h_{11} \quad h_{12} \quad h_{13} \quad h_{21} \quad h_{22} \quad h_{23} \quad h_{31} \quad h_{32}] \quad (40)$$

那么上式可以修改为矩阵形式

$$\begin{bmatrix} X & Y & 1 & 0 & 0 & 0 & -uX & -uY & -u \\ 0 & 0 & 0 & X & Y & 1 & -vX & -vY & -v \end{bmatrix} h' = 0 \quad (41)$$

上式是一个很经典的线性方程，我们将上式写为 $Sh' = 0$ ，那么矩阵 $S^T S$ 的最小特征值就对应该方程的最小二乘解。

2.2 求解内参矩阵

我们上面求得单应矩阵 H 可能和真实的值存在一个尺度因子，我们增加一个尺度因子 λ ，有

$$\lambda [h_1 \quad h_2 \quad h_3] = A [r_1 \quad r_2 \quad t] \quad (42)$$

由上节我们提到的旋转矩阵的性质可得两个约束条件

$$\begin{aligned} r_1^T r_1 &= r_2^T r_2 = 1 \\ r_1^T r_2 &= 0 \end{aligned} \quad (43)$$

调整上式，有

$$\begin{cases} \lambda h_1^T A^{-T} A^{-1} h_2 &= 0 \\ \lambda h_1^T A^{-T} A^{-1} h_1 &= h_2^T A^{-T} A^{-1} h_2 = 1 \end{cases} \quad (44)$$

我们知道， A 的逆矩阵为

$$A^{-1} = \begin{bmatrix} \frac{1}{\alpha} & \frac{-\gamma}{\alpha\beta} & \frac{\gamma v_0 - \beta u_0}{\alpha\beta} \\ 0 & \frac{1}{\beta} & -\frac{v_0}{\beta} \\ 0 & 0 & 1 \end{bmatrix} \quad (45)$$

令 $B = A^{-T}A^{-1}$ ，有

$$B = \lambda A^{-T}A^{-1} = \lambda \begin{bmatrix} B_{11} & B_{12} & B_{13} \\ B_{21} & B_{22} & B_{23} \\ B_{31} & B_{32} & B_{33} \end{bmatrix} \quad (46)$$

$$= \lambda \begin{bmatrix} \frac{1}{\alpha^2} & -\frac{\gamma}{\alpha^2\beta} & \frac{v_0\gamma-u_0\beta}{\alpha^2\beta} \\ -\frac{\gamma}{\alpha^2\beta} & \frac{\gamma}{\alpha^2\beta^2} + \frac{1}{\beta^2} & -\frac{\gamma(v_0\gamma-u_0\beta)}{\alpha^2\beta^2} - \frac{v_0}{\beta^2} \\ \frac{v_0\gamma-u_0\beta}{\alpha^2\beta} & -\frac{\gamma(v_0\gamma-u_0\beta)}{\alpha^2\beta^2} - \frac{v_0}{\beta^2} & \frac{(v_0\gamma-u_0\beta)^2}{\alpha^2\beta^2} + \frac{v_0}{\beta^2} + 1 \end{bmatrix} \quad (47)$$

使用上述约束式，就有

$$\begin{cases} h_1^T B h_2 = 0 \\ h_1^T B h_1 = h_2^T B h_2 = 1 \end{cases} \quad (48)$$

我们给出一个统一的表达形式

$$h_i^T B h_j = [h_{1i} \quad h_{2i} \quad h_{3i}] \begin{bmatrix} B_{11} & B_{12} & B_{13} \\ B_{21} & B_{22} & B_{23} \\ B_{31} & B_{32} & B_{33} \end{bmatrix} \begin{bmatrix} h_{1j} \\ h_{2j} \\ h_{3j} \end{bmatrix} \quad (49)$$

$$= [h_{1i}h_{1j} \quad h_{1i}h_{2j} \quad h_{2i}h_{2j} \quad h_{1i}h_{3j} + h_{3i}h_{1j} \quad h_{2i}h_{3j} + h_{3i}h_{2j} \quad h_{3i}h_{3j}] \begin{bmatrix} B_{11} \\ B_{12} \\ B_{22} \\ B_{13} \\ B_{23} \\ B_{33} \end{bmatrix} \quad (50)$$

令

$$v_{ij} = [h_{1i}h_{1j} \quad h_{1i}h_{2j} \quad h_{2i}h_{2j} \quad h_{1i}h_{3j} + h_{3i}h_{1j} \quad h_{2i}h_{3j} + h_{3i}h_{2j} \quad h_{3i}h_{3j}] \quad (51)$$

$$b = [B_{11} \quad B_{12} \quad B_{22} \quad B_{13} \quad B_{23} \quad B_{33}]^T \quad (52)$$

上式方程简化为

$$h_i^T B h_j = v_{ij} b \quad (53)$$

之前的约束方程变为

$$\begin{cases} v_{12}^T b = 0 \\ v_{11}^T b = v_{22}^T b = 1 \end{cases} \quad (54)$$

把上述方程矩阵化

$$\begin{bmatrix} v_{12}^T \\ v_{11}^T - v_{22}^T \end{bmatrix} b = v b = 0 \quad (55)$$

因为 v 本身都是由单应矩阵构成，所以上述又变成了一个方程求解的问题。

我们知道，每张标定图都可以提供一个上述约束关系(对应一个H)，而每个方程都会提供两个约束方程。 B 本身包含6个位置元素，因此理论上，三张标定图片就可以解出上述方程。当标定图超过3张时，也可以使用最小二乘法求解对应的超定方程。

当解出 B 时，我们可以继续求解出内参矩阵

$$\begin{aligned} v_0 &= \frac{B_{12}B_{13} - B_{11}B_{23}}{B_{11}B_{22} - B_{12}^2} \\ \lambda &= B_{33} - [B_{13}^2 + v_0(B_{12}B_{13} - B_{11}B_{23})]/B_{11} \\ \alpha &= \sqrt{\frac{\lambda}{B_{11}}} \\ \beta &= \sqrt{\frac{\lambda B_{11}}{B_{11}B_{22} - B_{12}^2}} \\ \gamma &= B_{12} - \alpha^2\beta\lambda \end{aligned} \quad (56)$$

$$\gamma = -D_{12}\alpha/\rho/\lambda$$

$$u_0 = \frac{\gamma v_0}{\beta} - B_{13}\alpha^2/\lambda$$

2.3 求解外参矩阵

我们知道

$$\begin{bmatrix} h_1 & h_2 & h_3 \end{bmatrix} = \lambda A \begin{bmatrix} r_1 & r_2 & t \end{bmatrix} \quad (57)$$

我们之前已经得到了 H 和 A ，那么得到

$$\begin{bmatrix} r_1 & r_2 & t \end{bmatrix} = A^{-1}H \quad (58)$$

可以很方便解得 $r_1 \ r_2 \ t$ ，但是缺少了 r_3 ，不过由于旋转矩阵的正交性，我们可以得到

$$r_3 = r_1 \times r_2 \quad (59)$$

对计算的 r 做归一化，我们就得到了对应的旋转矩阵 R 。

由于图像存在噪声，所以我们得到的 R 其实并不一定满足正交的性质，因此我们也使用优化的方法来得到最佳的 R ，令计算的值为 Q ，我们的问题变成了

$$\min_R \|R - Q\|_F^2 \quad \text{subject to } R^T R = I \quad (60)$$

矩阵 Frobenius 范数定义为 $\|A\|_F = (\sum_{i=1}^m \sum_{j=1}^n a_{i,j}^2)^{\frac{1}{2}}$ ，其可以被转化为矩阵内积的迹，具体证明大家可以自行查找

因为

$$\|R - Q\|_F^2 = \text{tr}((R - Q)^T(R - Q)) \quad (61)$$

$$= 3 + \text{tr}(Q^T Q) - 2 \text{tr}(R^T Q) \quad (62)$$

因此等价于最大化 $\text{tr}(R^T Q)$ 。

我们使用 SVD 将 Q 分解为 USV^T ，这里 $S = \text{diag}(\sigma_1, \sigma_2, \sigma_3)$ ，如果我们定义一个正交矩阵 $Z = V^T R^T U$ ，有

$$\text{tr}(R^T Q) = \text{tr}(R^T USV^T) = \text{tr}(V^T R^T US) \quad (63)$$

$$= \text{tr}(ZS) = \sum_{i=1}^3 z_{ii}\sigma_i \leq \sum_{i=1}^3 \sigma_i \quad (64)$$

明显，当 $Z = I$ 时，上式取最大值，此时 $R = UV^T$

Z 本身正交的性质是由旋转矩阵和 SVD 分解一起决定的

2.4 求解畸变系数

有了内参矩阵和外参矩阵，我们也可以采用最小二乘的方法近似拟合畸变初始解，构建如下方程

$$\begin{bmatrix} (u - u_0)(x^2 + y^2) & (u - u_0)(x^2 + y^2)^2 \\ (v - v_0)(x^2 + y^2) & (v - v_0)(x^2 + y^2)^2 \end{bmatrix} \begin{bmatrix} k_1 \\ k_2 \end{bmatrix} = \begin{bmatrix} \delta u \\ \delta v \end{bmatrix} \quad (65)$$

把上式写为 $Dk = d$ ，那么使用最小二乘解就可以得到

$$k = (D^T D)^{-1} D^T d \quad (66)$$

2.5 最小二乘优化

当有了上述初始解时，我们把所有的参数整合一起，使用非线性优化方法来优化最终的结果。

3. 聊聊单应矩阵

上一节的内容我们大量使用了单应矩阵来计算标定板平面和像素平面的变换关系，其本身已经包含了相机的内参以及标定板和相机的外参矩阵。实际上，在射影几何中，单应矩阵更多的被用来表征两个图像平面之间的变换关系。我们知道，标定时

$$s \begin{bmatrix} u \\ v \end{bmatrix} = \mathbf{A} [R \quad T] \begin{bmatrix} X_W \\ Y_W \\ 1 \end{bmatrix} \quad (67)$$

$$\begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} Z_W \\ 1 \end{bmatrix}$$

我们依然令 $Z = 0$, 并把中间复杂的部分写作 M 有

$$\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \mathbf{M} \begin{bmatrix} X_W \\ Y_W \\ 1 \end{bmatrix} \quad (68)$$

如果存在不同的两个相机, 或者相同的相机在不同位置看到同一个平面, 则有


$$\begin{bmatrix} u_2 \\ v_2 \\ 1 \end{bmatrix} = \mathbf{M}_2 \begin{bmatrix} X_W \\ Y_W \\ 1 \end{bmatrix} = \mathbf{M}_2 \mathbf{M}_1^{-1} \begin{bmatrix} u_1 \\ v_1 \\ 1 \end{bmatrix} = \mathbf{H} \begin{bmatrix} u_1 \\ v_1 \\ 1 \end{bmatrix} \quad (69)$$

也就是, 存在一组关系, 可以实现两个像素平面的互相变换。其具体的计算和前面标定时是类似的


同样的, $\mathbf{H}$ 矩阵只有8个自由度, 因此只需要四组对应点就可以计算出

有了这个关系, 我么能能做什么呢?

- 图像校正



- 视角变换



- 图像拼接

